

Avaliação final

Quando o arquivo mpg_desafio_final.csv for liberado, rodem o modelo de vocês nele e reportem o R^2 pra lousa.

LEMBRETE DE SINTAXE

```
df_final = pd.read_csv("mpg_desafio_final.csv")
X_final = df_final[["weight"]] # mesma feature escolhida
y_final = df_final["mpg"]

r2_score(y_final, modelo.predict(X_final))
```

Por que os R^2 de vocês variaram tanto entre si, mesmo seguindo o mesmo roteiro?



Duas fontes de sorte, misturadas

Quando cada dupla escolheu seu próprio `random_state`, DUAS coisas mudaram ao mesmo tempo: qual modelo foi treinado (quais carros caíram no treino) E qual 'prova' foi aplicada (quais carros caíram no teste).

Essas duas fontes de sorte giram JUNTAS, no mesmo sorteio — por isso o R^2 que cada dupla mediu de si mesma pode ter variado bastante, sem isso refletir diferença real de qualidade entre os modelos.

Um R^2 sozinho mistura 'o modelo é bom?' com 'a prova calhou fácil ou difícil?' — sem separar as duas coisas.



A revelação: compare os números

Rodamos o mesmo modelo (mesma feature, mesmo grau) em 30 seeds diferentes, e comparamos duas formas de medir o R^2 :

R^2 PRÓPRIO (teste de cada dupla): média 0,585 — desvio padrão 0,057 — faixa de 0,498 a 0,718

R^2 OFICIAL (conjunto final, fixo pra todos): média 0,590 — desvio padrão 0,005 — faixa de 0,578 a 0,598

O desvio do R^2 oficial é mais de 10x menor — porque a ‘prova’ deixou de variar, só o modelo.



O que procurar pra saber se o modelo está bom

- 1 Média estável em várias rodadas, não um pico isolado
- 2 Desvio padrão baixo entre rodadas (modelo consistente)
- 3 R^2 do treino perto do R^2 do teste (sem overfitting)
- 4 Bom desempenho no conjunto verdadeiramente novo (o oficial)
- 5 Comparação relativa: melhor que a alternativa mais simples?



Bônus, pra quem terminar cedo

Tentem combinar 2 features (ex: weight + horsepower) no mesmo modelo.

O R^2 melhora? Por que será que não melhora tanto quanto parece que deveria?

Dica: olhem se as duas features escolhidas já são correlacionadas entre si.



FECHANDO O DESAFIO

O que fica desse desafio

1

A escolha da feature e o tratamento de nulos pesaram mais que o grau do polinômio.

2

Um R^2 medido no PRÓPRIO teste de cada dupla é bem menos confiável do que parece — ele mistura sorte de divisão com qualidade real do modelo.

3

O conjunto de avaliação fixo (o mesmo pra todo mundo) é o que torna a comparação honesta — é assim que ML de verdade avalia modelos.

